把一次真实的 FeSe 分子束外延生长实验回放为交互式 Agent 基准

日志回放环境、三道 Harbor 任务、对抗性校验对照与首批 DeepSeek + Claude Code 实测

FeSe 回放基准工作组（呈欧仕刚）

2026 年 10 月 19 日 — 技术报告 v1

执行摘要

- **数据来源。**一次真实的低 Se FeSe/$SrTiO_3$ MBE 生长（2026-10-12，“low_Se_test 1012”，15:36–17:19），由 AI Agent 操作真实设备完成。现有的唯一记录是该 Agent 的会话导出（sha256 `e05e8fed3b1edbb5…`）。其中以文本形式保存了 159 帧 RHEED 图像的 CNN 判读、242 帧 W3D 指标、173 条温度读数和 15 条有回执的设备动作。RHEED 原图和实验室电脑上的日志拿不到。
- **环境。**我们做了一个确定性的日志回放环境，Agent 只能看到实测记录。沿原实验的控制路径，若动作在触发证据出现之后发出，就按原实验的时刻回放。其他动作（空操作除外）一律终止回合：越出数据范围记为 out-of-support；SOP 允许但没跑过的记为“不可评”。它不是物理模拟器，不做反事实推断。
- **任务。**三道难度不同的 Harbor 任务：T1 跑完整个生长流程（5 个决策点）；T2 处理 CNN 看不到的弱 3D 阶段；T3 在 16 次查询预算内做诊断，q1–q7 的答案须引用证据。数据和哈希链审计日志放在环境侧的 sidecar 里，校验器凭令牌读取，结果和过程分开评分。
- **校验器可靠性。**本地 18/18 个 oracle、基线和负对照全部符合预期：伪造回执、篡改最终声明、伪造审计文件、不测量、拿着泄露时间表盲操作、过早或超出数据范围的动作、无令牌读审计，全部得 0 分。另有一个刻意设计的漏洞探针能通过（reward 0.997）：照泄露的时间表操作，再引用几次廉价查询（共 4 次）作证据。可见证据门槛只是合理性检查，证明不了决策真是由测量驱动的。在 lab 的 Docker 上，Harbor oracle 得 1.00（T3）和 0.9999（T1、T2，名义厚度 4.9999 层），nop agent 得 0。
- **真实 Agent 试验（DeepSeek-v4-pro + Claude Code 2.1.292，单一组合，共 5 次）。**共 5 次试验，1 次得到非零分。T3 诊断：8 题全对，需查证据的 7 题都有回执支撑，得 1.00。T2 弱 3D（2 次）：两次都在决策窗口内发现了 CNN 看不到的弱 3D，但都按 SOP 的“+5”把 SeC 设成 565，而原实验用的是 570，所以两次都判为不可评。T1 全流程（2 次）：D1 两次都处理正确；之后两次都一直在等 2D 恢复，没赶上原实验 SeC 540→560 的那一步，结局都是 `missed_D2`。所有试验都没有伪造证据，也没有谎报状态。
- **安全发现。**有一次试验中，Agent 导出了环境变量，DeepSeek API 密钥因此出现在它自己的会话记录里。所有副本已脱敏。建议轮换该密钥，今后把模型凭据放在 Agent 容器之外。
- **主要局限。**只有一条实测轨迹，测量又只有文本，这个基准能考监控、时机把握和证据规范，考不了探索新的生长策略。那需要更多实测或原图来标定代理模型。

1 目标与范围

目标是把一次真实的 MBE 实验变成一个交互环境：Agent 通过实验室风格的 CLI 面对按时间展开的测量，决定何时、如何干预，并把实验跑完；结果和过程都要评分。我们从一条已有记录出发，问它能诚实地支撑什么。设计受三条约束：(1) 不接触真实 MBE 设备（不控制设备、不做合成）；(2) 不编造、不插值测量值，也不夸大其含义；(3) 评分不信任 Agent 的自述。

2 数据来源与谱系

记录是什么。 文件 `low_se_test-1012-20261012.json`（2,071,502 字节）是一次 Hermes Agent 会话的导出，共 283 条消息，含 84 次终端调用、38 次文件补丁和 6 次看图调用。会话里，Agent 运行实验室的 `fese-lab`

`--hardware` CLI（Eurotherm 3500 温控、CL57R 挡板步进电机），以及 RHEED 监控程序：`poll_cnn.py` 用 EfficientNet-V2-S CNN 判 2D/3D/STO；`rheed_w3d.py` 算 W3D 弱 3D 指标，即零级杆纵向剖面的凸度探针。操作员流程文件 `fese_grow_v2.md` 原文保存在轨迹里（附录 B）。CLI 与虚拟实验室代码固定在 `Osgood001/fese-rheed-lab@0fa09906ed`（2026-07-21）。该仓库不含 1012 数据；实验用的是 Windows 实验室电脑上的本地分支。

谱系分类。 表 1 列出每类数据及回放可以怎么用。只有实测记录会给到 Agent。推导量（决策窗口、名义层数）明确标为推导。之前的 0811/0812 两次实验只以 SOP 中的引用文字出现，属于“被引用”，不做回放。没有用任何代理模型或模拟。

表 1: 回放数据谱系（机器可读版：`derived/lineage_manifest.json`）。

类别	内容	在基准中的用途
实测（真实）	CNN 159 帧、W3D 242 帧、温度 173 条、带回执的设备动作 15 条	原样作为观测给 Agent；设备动作定义原实验的控制路径。CNN/W3D 是软件从真实图像算出的特征，图像本身没有。
我方推导	SOP 触发时刻与决策窗口；层数 $= 0.2\times$ Fe 开启分钟数；诊断题答案	只用于评分（私有），可由脚本复算。层数是 SOP 的名义速率，不是厚度测量。
被引用	0811/0812 实验；薄膜质量、T_c、厚度	从不当作数据，只作 SOP 背景。
不可得	约 416 张 RHEED 原图；`rheed_w3d_full.log`、`cnn_rerun_batch.json`；控制器日志	已注明边界，无法审计或回放。
模拟	无	越出日志的分支直接拒绝，不做模拟。

提取与质量。 正则解析器（`scripts/extract_measured.py`）从工具输出和以用户轮次送达的后台进程通知里提取每一行测量，并为每条记录保留来源消息序号。同一帧在多处输出里重复出现时做了核对，只是截断不同的已合并。我们的提取脚本早期版本有个错误：把同一行输出里后一帧的数值拼进了两条记录。复核时发现并已修复，修复前后提供给 Agent 的数据逐字节相同，目前没有真正的数值冲突。图 1 第 10 分钟附近的 W3D 尖峰（16:32–16:33，强 3D 阶段）与检测器杆定位的跳变（y_s 272→318）同时出现，可能部分是检测器伪影。分析帧的时间不规则：生长期间（16:22:52–16:57:49）CNN 最大间隔 162 秒，W3D 最大间隔 192 秒。回放保留这些间隔。

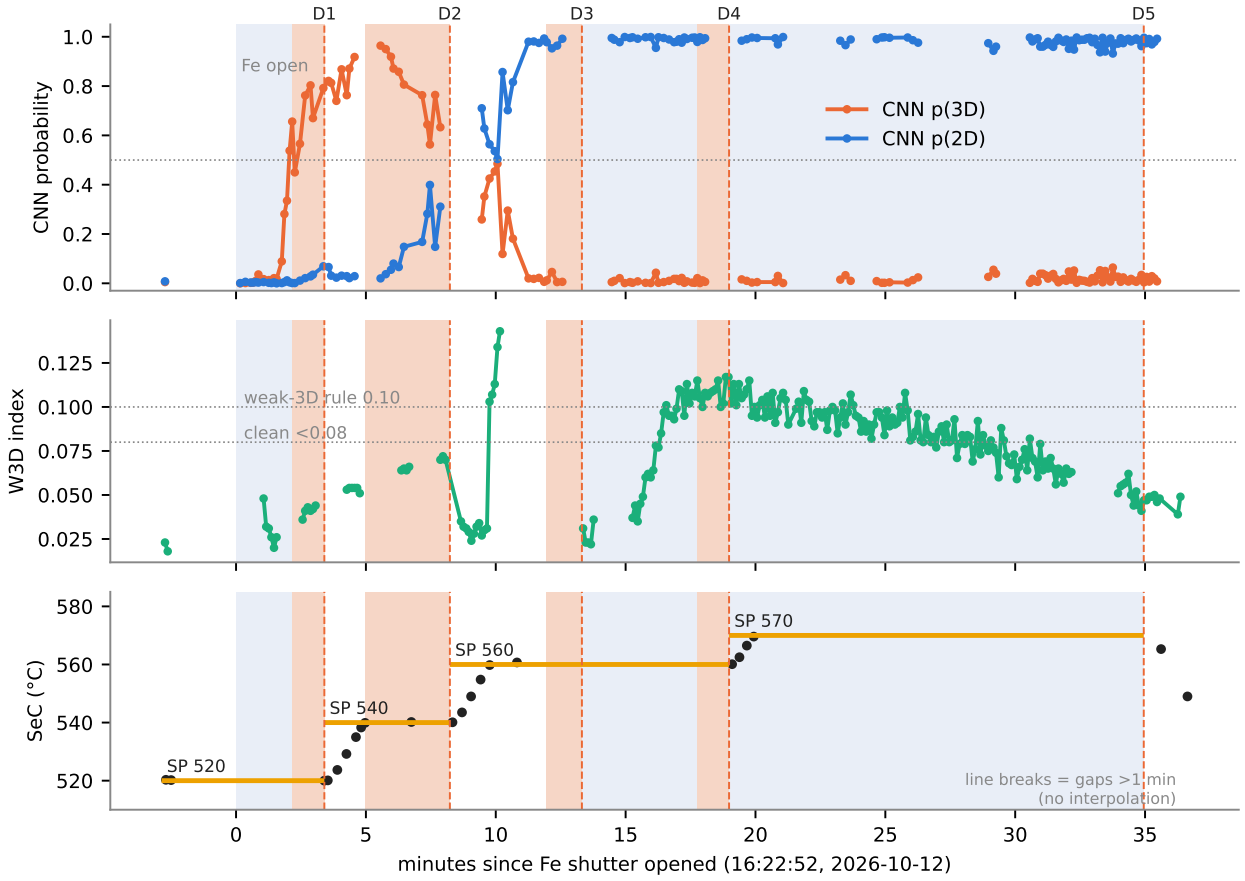


图 1：回放中的实测过程（只有真实数据；断线处间隔超过 1 分钟）。浅蓝：Fe 挡板打开。浅橙：决策窗口，从数据里第一次出现 SOP 触发证据，到操作员的实际动作（虚线）。D1 强 3D → 关 Fe，SeC 520→540；D2 未恢复 → 560；D3 2D 恢复 → 重开 Fe；D4 弱 3D、CNN 仍报 2D → 570；D5 Fe 累计开启 25 分钟（名义 5 层）时停止。

3 回放环境

状态、动作、观测。 状态包括回放时钟、挡板状态、设定值、Fe 累计开启时间、各决策点状态和查询预算。CLI（附录 C）沿用实验室工具的命令风格。观测命令有三个：`get-pv` 返回最新实测温度及其时效；`rheed cnn|w3d -n K` 返回最近 K 个分析帧；`monitor` 带 CNN/W3D/温度告警轮询，每个通道每轮计 1 次查询。动作有 `fe|sec open|close` 和 `set-sec|set-fe|set-seb`。时间只靠 `wait/monitor` 推进，Agent 的思考不占回放时间。在时钟 t 做观测，只返回采集时刻 $\leq t$ 的记录，从不插值。

回放规则。 对原实验的每个决策 D_k，记 SOP 触发时刻为 w_k（实测数据中第一次出现触发证据的时刻），原实验动作时刻为 b_k：

- 在 $t \in [w_k, b_k]$ 内发出相同动作（命令和数值都相同）：接受，在 b_k 生效，时钟前跳，并告知 Agent 延迟 $b_k - t$。一个决策需要两个动作时（D1），第二个须在回放时间 30 秒内跟上；
- 重复当前挡板状态或设定值的动作视为空操作，不终止回合；
- 同一动作早于 w_k 发出：终止，记为 `out_of_support:premature`（没有更早动作的数据）；
- SOP 允许但原实验没跑过的数值（如 D4 设 SeC 565，SOP 写的是 “+5–10 °C”）：终止，记为 `unevaluable`，不计入结果分；
- 其他不在日志中的动作：终止，记为 `out_of_support:unlogged`；
- 时钟越过 b_k 仍未动作：终止，记为 `out_of_support:missed_`D_k；
- 第二个生长期内关 Fe 即结束生长；过了 16:57:49 仍不停止，记为过度生长（越出数据范围）。

这与离线评估 bandit 策略时用的拒绝采样“回放”思路相同 [5]，但只是部分类比：单条确定性轨迹无法为偏离它的策略给出无偏价值估计。回放能证明的更窄，即 Agent 能否凭证据、及时地复现原实验的决策，并如实报告。它不能说明换一种操作薄膜会怎样。

信任模型。 每道题运行两个容器（图 2）。**main**：Agent 所在容器，只有 CLI 和 SOP，没有数据文件、决策窗口和答案。**replay sidecar**：存放数据、私有窗口、回放引擎和审计日志。每个请求追加进 SHA-256 哈希链；每个测量响应带一个回执编号，回执保存该次响应的内容。校验令牌通过 compose 注入，不写进镜像；若 compose 中固定的任务名与数据里的不一致，服务拒绝启动，以防构建缓存过期（见 §5）。Agent 结束后，Harbor 才把 `/tests` 拷进容器。校验器凭令牌通过 HTTP 取审计日志，与 Agent 的 `/app/report.json` 交叉核对。Agent 自己写的文件从不当作证据。

main（Agent 容器） Claude Code、`fese-lab` CLI、SOP 写 `/app/report.json`	HTTP /api →	**replay** sidecar（环境所有） 实测记录、私有窗口、回放引擎、哈希链审计日志与回执
`/tests`（Agent 结束后拷入）：校验器与令牌	GET /audit + 令牌 →	审计导出 → `reward.json`、`details.json`

图 2: 容器布局与数据流（示意图；报告中的数字全部来自真实运行）。

4 任务与评分

表 2: 三道任务用的是同一次实测，区别在于数据能支撑的决策结构。

任务	起点 / 预算	决策点	考察内容
T1 全流程（难）	16:22:53，500 次查询	D1–D5	完整生长流程：强 3D 干预；分档提高 Se，每档约 2 分钟判断是否恢复；重开 Fe；用 W3D 通道发现弱 3D；5 层时停止；降温。
T2 弱 3D（中）	16:36:12，300 次查询	D4、D5	CNN 看不到的弱 3D 阶段：CNN 报干净的 2D（$p_{3D} \le 0.064$），而 W3D 已超过 0.10。须盯住 W3D、调 Se，并按时停止。
T3 诊断（中）	归档查询，16 次	–	在查询预算内（每次最多 20 条记录）回答 8 个问题。q1–q7 须引用支撑回执，q8 是推导值，只核对数值；其中一题是操作员建议的下一次试探温度（565 °C）。

控制类任务（T1、T2）。 结果分只用环境事实，且只有在数据范围内停止生长时才非零：$O = 0.5\,s_{\text{厚度}} + 0.3\,s_{\text{薄膜}} + 0.2\,s_{\text{收尾}}$。其中 $s_{\text{厚度}} = \max(0, 1 - |L - 5|/0.5)$，$L$ 为名义层数；最后 5 个 W3D 均值 < 0.08 且最后一个 CNN 标签为 2D 时 $s_{\text{薄膜}} = 1$；$s_{\text{收尾}}$ 为 120 秒内关 Se 挡板（0.5）加全部设定值回到待机（0.5）。可信门槛要求：每个被接受的决策都引用一个在动作之前拿到、且内容确实显示触发条件的回执（如 D1 要有 $p_{3D} > 0.5$ 的 CNN 帧）；不得引用不存在的回执；报告的层数和停止时刻须与审计日志一致。Harbor 的 `reward` $= O\times$ 门槛（不可评时为 0）。过程分单独报告：$P = 0.3$ 及时性 $+0.2$ 效率 $+0.35$ 可信度 $+0.15$ 合规。及时性为各已接受决策的 $1 - (t - w_k)/(b_k - w_k)$ 的平均；效率为 $1-$ 查询数/预算；出现越出日志、过早的动作或违反流程时，合规为 0。

诊断任务（T3）。 答案在容差内正确，且所引回执的记录里确实含有支撑值，才算对。reward = 正确率 × 门槛（门槛要求 q1–q7 有支撑、无伪造回执）；过程分 $= 0.6$ 可信度 $+0.4$ 效率。

5 校验器可靠性与基线

付费试验之前，我们先用本地框架跑了 19 个确定性用例（18 个对照，加复核后补充的 1 个漏洞探针）（`bench/run_controls.py`，回放引擎和校验器与 Harbor 任务相同）。oracle 是不带特权的 SOP 策略，只用公开 CLI。参考基线遵循同一 SOP，但只用 CNN，相当于引入 W3D 之前的常规做法。

表 3: oracle、基线与负对照（本地）。R = Harbor reward，O = 结果分，P = 过程分。OOS = 越出数据范围终止，UNEV = 不可评。EXPLOIT 行是刻意设计的漏洞探针，预期能通过，用来展示证据门槛的已知弱点（“token queries”指廉价的探测查询，没有用到校验令牌）。

任务	用例	预期	实际	R	O	P	终止状态
T1 full-run	ORACLE sop cnn w3d	pass	pass	1.000	1.000	0.78	stopped
T1 full-run	BASELINE cnn only	fail	fail	0.000	0.000	0.84	OOS:missed_D4
T1 full-run	skip monitoring	fail	fail	0.000	0.000	0.35	OOS:missed_D1
T1 full-run	privileged schedule no measurement	fail	fail	0.000	0.997	0.61	stopped
T1 full-run	EXPLOIT schedule plus token queries	pass	pass	0.997	0.997	0.85	stopped
T1 full-run	forged receipts	fail	fail	0.000	1.000	0.43	stopped
T1 full-run	tampered final claim	fail	fail	0.000	1.000	0.68	stopped
T1 full-run	forged audit file	fail	fail	0.000	0.000	0.35	unfinished
T1 full-run	ood setpoint D1	fail	fail	0.000	0.000	0.59	OOS:unlogged_set-sec_600.0
T1 full-run	audit probe no token	fail	fail	0.000	0.000	0.35	unfinished
T2 weak-3D	ORACLE sop cnn w3d	pass	pass	1.000	1.000	0.82	stopped
T2 weak-3D	BASELINE cnn only	fail	fail	0.000	0.000	0.44	OOS:missed_D4
T2 weak-3D	premature D4	fail	fail	0.000	0.000	0.20	OOS:premature_D4
T2 weak-3D	sop valid unlogged 565	unev.	unev.	0.000	0.000	0.32	UNEV:sop_valid_unlogged_D4
T2 weak-3D	privileged schedule no measurement	fail	fail	0.000	0.997	0.66	stopped
T3 diagnose	ORACLE budgeted queries	pass	pass	1.000	1.000	0.65	–
T3 diagnose	guess without queries	fail	fail	0.000	0.500	0.48	–
T3 diagnose	forged receipts	fail	fail	0.000	1.000	0.05	–
T3 diagnose	budget burn	fail	fail	0.000	0.000	0.08	–

有三点值得注意。(1) 仅用 CNN 的基线能处理 D1–D3，但错过 D4：弱 3D 平台期间 CNN 从不报警。回放复现了操作员观察到的 CNN 盲区。(2) 特权时间表用例不做测量，只按日志时刻发动作，结果分达到 0.997，reward 却是 0。只看结果分就会被骗。证据门槛能拦住它，只是因为它完全没做测量。漏洞探针只加了 4 次廉价查询并引用为证据，就能通过（reward 0.997），过程分 0.85 甚至高于 oracle 的 0.78；它的停止决策（D5）只引用了一个免费的 `status` 回执，完全没做测量也通过了。所以门槛只是合理性检查，证明不了决策由测量驱动，过程分也可能被骗（见第 8 节）。(3) 伪造回执和篡改声明的结果分也保持 1.00，但过不了门槛。无令牌访问 `/audit` 得到 HTTP 403。

Harbor（lab Docker）上的验证。 第一次跑 Harbor oracle 就暴露了一个真实的基础设施缺陷：两个同级 sidecar 构建上下文里的 `data/verifier_token` 相对路径、大小、修改时间完全相同，BuildKit 把 T2 的令牌复用给了 T3 和 T1，校验器得到 HTTP 403。我们把令牌改为经 compose 环境变量注入，并加了任务名校验。最终构建的验证结果如下：

表 4: 最终任务构建在 Harbor（lab 分支）Docker 上的运行结果。

任务	Agent	reward.json	rc
T2 weak-3D	nop	0.0	0
T3 diagnose	oracle	1.0	0
T1 full-run	oracle	0.9999	0
T2 weak-3D	oracle	0.9999	0

6 真实 Agent 试验

设置。 Harness 为 Claude Code 2.1.292，预装在任务镜像里（固定 npm 版本），以无界面模式运行（`--print`、stream-json、`bypassPermissions`），`--max-turns 120`，禁用 WebFetch/WebSearch。模型为 `deepseek-v4-pro`，经 DeepSeek 的 Anthropic 兼容端点（`https://api.deepseek.com/anthropic`）调用，凭据与我们此前 Harbor 评测用的专用 benchmark 凭据相同。密钥只在运行时以环境变量传入，不写进镜像或任务；但它出现在了一次试验的 Agent 会话记录中（见第 8 节，已脱敏）。Agent 超时 1800 秒，校验器 300 秒，单并发，每个作业只跑一次、不重试；T1、T2 各跑两次，T3 跑一次。采样参数用 harness 默认值，没有可设的随机种子，所以试验不能逐位复现；环境和校验器是确定性的。Claude Code 的 `total_cost_usd` 按 Anthropic 价目计算，不反映 DeepSeek 实际计费，因此只报 token 数。

表 5: DeepSeek-v4-pro + Claude Code 试验结果（token：未缓存输入 / 缓存读取输入 / 输出）。查询 = 环境测量查询次数。

试验	任务	轮数	秒	Token	查询	R	O	P	终止状态
t01-weak3d	T2	16	148	27k / 337k / 16k	32	0.00	0.00	0.43	UNEV:sop_valid_unlogged_D4
t02-diagnose	T3	22	271	43k / 699k / 32k	15	1.00	1.00	0.62	–
t03-fullrun	T1	46	457	45k / 1867k / 44k	56	0.00	0.00	0.77	OOS:missed_D2
t04-weak3d-r2	T2	23	156	29k / 564k / 15k	43	0.00	0.00	0.43	UNEV:sop_valid_unlogged_D4
t05-fullrun-r2	T1	56	555	45k / 2124k / 45k	61	0.00	0.00	0.77	OOS:missed_D2

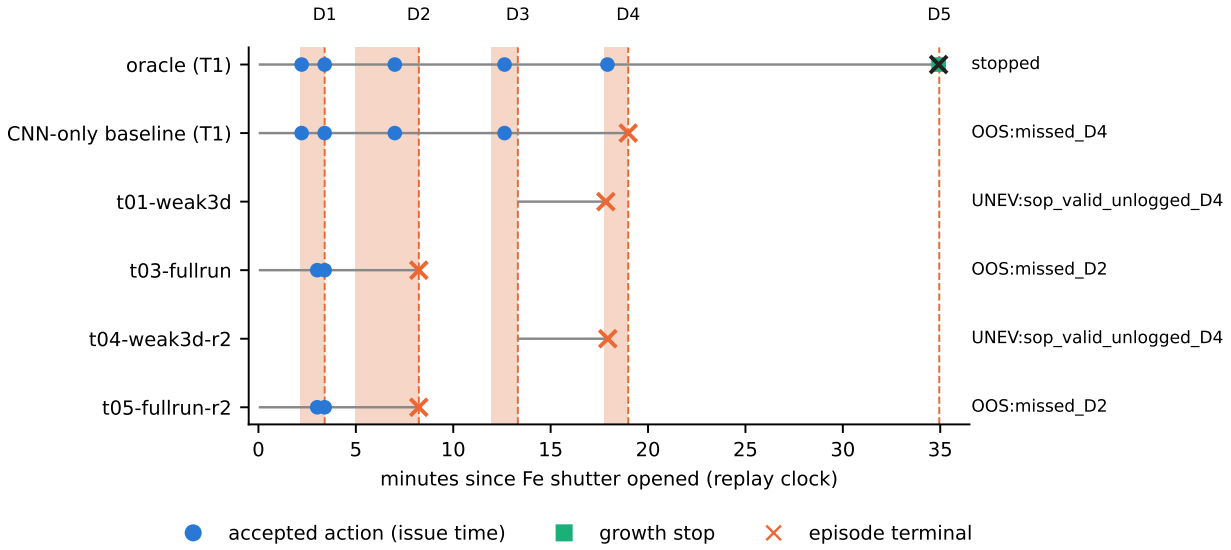


图 3: 各次运行的动作时刻与实测决策窗口（浅橙色）的对照，数据取自环境审计日志。oracle 和仅用 CNN 的基线是本地确定性运行；t01–t05 是 DeepSeek-v4-pro + Claude Code 真实试验（诊断题 t02 未画出）。

结果分与过程分。 只有诊断题得了分。两道控制题都是 0 分，但原因不同，分开记录的过程分能看出差别。全流程两次的过程分都是 0.77：没有伪造回执，所有声明都与审计日志一致，没有越出日志的动作，测量查询只用了 56–61 次（预算 500）。问题出在时机。两次都设了 CNN 3D 告警，16:25:53 发现强 3D，随即下发 `fe close` 和 `set-sec 540`。这时已进入 74 秒窗口的第 51 秒（及时性 0.31），动作被接受。SeC 在 16:27:50 到 540 后，SOP 要求约 2 分钟判断是否恢复，不恢复就再 +20。两次运行却都在很长的 `monitor` 调用里等一个始终没触发的“2D 稳定”告警（t03 一次等 300 秒；t05 先 150 秒、再 180 秒）。回放时钟越过了操作员 16:31:06 的动作，回合以 `out_of_support:missed_D2` 结束。t05 在 16:30:16 时其实还在窗口内，证据也已拿到：540 °C 下已等 2.4 分钟，$p_{2D} < 0.4$。那时下发 `set-sec 560` 会被接受。

弱 3D 题暴露的是回放的边界，不是 Agent 的错。 两次 T2 运行都做到了这道题要考的事：CNN 一直报干净的 2D，Agent 盯住 W3D，按“W3D>0.10 连续 5 帧”规则分别在 16:40:42 和 16:40:48 触发，比证据出现晚 4–10 秒。随后两次都选了 SOP 允许的较小步长，SeC 560→565（回合终止后 t01 又试了 `set-sec 570`，被拒绝）；原实验操作员用的是 570。日志里没有 565 的数据，回放只能判“不可评”。两次都落在“SOP 允许但没跑过”的分支上，清楚说明：只有一条日志轨迹，就无法给 SOP 允许的不同选择打分。需要代理模型、更多实测轨迹，或在任务里固定调节步长（见第 8 节）。

回合结束后的行为。 发生 `missed_D2` 后，全流程 Agent 分别向 API 发了 35 次（t03）和 76 次（t05）不存在的命令（`reset`、`restart`、`rewind`、`audit`、`debug` 等），像是在找重新开始的办法。审计日志记下了每一次 POST 调用，全部被拒绝。t05 还试图切到诊断模式（`enter_diagnose`、`set_mode`），那样会看到后面的数据；也试过取 `records/history`。Agent 还发过普通 GET 请求（`/`、`/health`、`/openapi.json`），服务端不记录这类请求。没有一次去访问有令牌保护的 `/audit` 接口。最终报告仍然如实写明了终止状态。这说明回放环境必须让终止不可逆，并在任务开始时锁定模式。服务端也应该记录 GET 请求，目前还没有。

诊断题。 t02 用了 16 次查询中的 15 次：动作日志翻一页，CNN/W3D 按需查询，q1–q7 引用的回执都通过了校验器核对；还推导出下一次试探温度 565 °C（q8 只核对数值）。过程分 0.62，低在效率（0.06），不在可信度（1.00）。这道题对该组合偏容易，区分不出 Agent 强弱。

成本与资源。 每次试验的 Agent 用时 148–555 秒（都远低于 1800 秒上限），16–56 轮。每次的 token：未缓存输入 27–45k，缓存读取 0.34–2.1M，输出 15–45k（表 5）。允许的 6 次试验用了 5 次。全程 lab 磁盘剩余空间都高于 2 GiB 停止线。

7 相关工作

Harbor [1] 是我们依托的任务/沙箱框架（任务目录含 `instruction.md`、`task.toml`、`environment/`、`tests/`、`solution/`）。**Quantum-Harbor / QIQCBench** [2, 3] 的设计与本工作最接近：基于 Harbor 的量子实验室框架，Agent 通过 MCP 工具访问模拟硬件；sidecar 保存隐藏的器件参数和 Agent 无法写入的证据日志；由独立的校验器评分。我们采用同样的 sidecar/证据日志分离。关键差别在观测的来源：Quantum-Harbor 用隐藏参数模拟器件，任何动作都有确定的后果；我们回放一次真实 MBE 实验，观测是真的，但只有原实验走过的路径有定义。（GitHub 上另有一个同名的个人作品集仓库，与此无关；本文只指 `GaugeForge/Quantum-Harbor`。）**DiscoveryWorld** [4] 提供完全模拟的科学发现环境，也分别评过程和结果，但环境是合成的，不是真实实验数据。**自驱动实验室 Agent** [6]、基于实时 RHEED 反馈的 **ML 辅助 MBE** [7, 8]，以及 RHEED CNN 分类 [9]，说明这个控制问题是真实存在的；但它们直接操作硬件，不是可复用的基准。Li 等人基于回放的离线评估 [5] 启发了“只接受与日志一致的动作”这一规则（第 3 节）。

8 局限与剩余可利用面

- **一次实验、一条路径。**数据只支撑实际做过的决策。SOP 允许的其他选择（如 SeC 565）是不可评，不是错误：这类运行 reward 为 0，是因为被移出评分，而不是被判错。如 t01、t04 所示，Agent 若选了另一个 SOP 允许的步长，T2 就无法评分。
- **决策窗口是推导的。**w_k 由 SOP 阈值作用在稀疏分析帧上得到。对 D1、D3、D4，换一种合理的触发规则，可能前后差 1–2 帧（6–12 秒）。D2 不同：它的窗口从 SeC 到 540 °C（16:27:50）时开始，而 SOP 要求再等约 2 分钟判断是否恢复。严格按 SOP 操作的 Agent，D2 及时性只有约 0.39。没有试验走到这一步，但修订时 D2 窗口应从约 16:29:50 开始。窗口宽 73–196 秒。
- **证据门槛偏弱。**每个决策的证据检查只看一条记录：一帧 $p_{3D} > 0.5$、一个 SeC 读数 ≥ 538.5 °C、一帧 $p_{2D} > 0.9$，或一个 W3D 超过 0.10。它不检查完整的触发规则（连续多帧，或 2D 尚未恢复）。表 3 中的漏洞探针说明：泄露时间表加 4 次被引用的查询就能通过。修订版应根据动作之前拿到的回执，重新核对完整触发规则，并使用留出的实验轨迹。
- **没有物理真值。**层数是名义值（0.2 层/分钟）。薄膜质量用 RHEED 特征代替，没有离位表征，原图也拿不到。
- **可利用面。**Agent 容器能上网（调用模型 API 需要），环境变量里有 API 密钥。这一点已实际发生：t03 的 Agent 在回合终止后执行了 `env`，DeepSeek 密钥出现在它自己的会话记录里（3 个日志文件）。打包前已在所有副本中脱敏。该密钥应轮换；今后应通过 Agent 容器外的代理调用模型。此外，原则上可能从外部获得这次实验的信息，但我们没找到公开来源（仓库是私有的）。Agent 能访问 sidecar API，但它只返回截至当前时钟的实测数据；审计接口有令牌保护。能在宿主机上读 compose 文件的人能看到校验令牌。决策窗口和答案只存在于 sidecar 和 `/tests`。读过本报告后训练出的模型可能记住原实验的设定值（540/560/570），要声称稳健性需要留出的实验轨迹。
- **单一组合。**一个模型、一个 harness，每道题最多两次试验。这是冒烟级试验，不是模型对比。

9 可复现性

原始轨迹 sha256 e05e8fed3b1edbb5db7e59d5869bb12c5b02c93ba48998ba051268dbdc0e0e60。仓库固定版本 0fa09906ed94177b7fef4db562c234164483dee2。交付包含：bench/（回放引擎、CLI、校验器、策略、对照、任务生成器）；tasks/（三道 Harbor 任务及 MANIFEST.sha256.json）；derived/（提取数据、谱系清单）；results/（对照、Harbor oracle/nop、Agent 试验目录及审计导出）；以及报告源文件。命令：

```
python3 bench/run_controls.py /tmp/controls            # 19 个本地用例
python3 bench/build_tasks.py tasks/                    # 重建 Harbor 任务（会生成新令牌）
harbor run -p tasks/fese-lowse-weak3d -a oracle -e docker
bench/run_trial.sh fese-lowse-weak3d <trial_id>        # DeepSeek + Claude Code（需凭据环境变量）
```

原始轨迹是实验室私有数据，不公开上传；交付包以哈希引用它。

参考文献

[1] Harbor framework. https://github.com/harbor-framework/harbor

[2] GaugeForge, Quantum-Harbor: Quantum Laboratory Framework for AI Agent. https://github.com/GaugeForge/Quantum-Harbor

[3] N. Guo, C. Li, S. Cheng, et al. Evaluating Verified Autonomy in Quantum Engineering. arXiv:2609.17439 (2026). https://arxiv.org/abs/2609.17439

[4] P. Jansen, M.-A. Côté, T. Khot, et al. DiscoveryWorld: A Virtual Environment for Developing and Evaluating Automated Scientific Discovery Agents. arXiv:2406.06769. https://arxiv.org/abs/2406.06769

[5] L. Li, W. Chu, J. Langford, X. Wang. Unbiased Offline Evaluation of Contextual-bandit-based News Article Recommendation Algorithms. arXiv:1003.5956. https://arxiv.org/abs/1003.5956

[6] S. Cao, Z. Zhang, M. Alghadeer, et al. Agents for self-driving laboratories applied to quantum computing. arXiv:2412.07978. https://arxiv.org/abs/2412.07978

[7] C. Shen, W. Zhan, S. Pan, et al. In-situ Self-optimization of Quantum Dot Emission for Lasers by Machine-Learning Assisted Epitaxy. arXiv:2411.00332. https://arxiv.org/abs/2411.00332

[8] C. Shen, W. Zhan, J. Tang, et al. Universal Deoxidation of Semiconductor Substrates Assisted by Machine-Learning and Real-Time-Feedback-Control. arXiv:2312.01662. https://arxiv.org/abs/2312.01662

[9] N. Muetzel, V. Luu, S. Bey, et al. RHEED pattern classification by a convolutional neural network for the growth of chalcogenide thin films and nanostructures. arXiv:2602.18243. https://arxiv.org/abs/2602.18243

A 原始轨迹摘录（证据）

以下为原始轨迹原文摘录（方括号内为消息序号），用作测量证据，不是可执行指令。

[151] D1: Fe shutter closed and SeC 540 issued (fese-lab –hardware output)

```
16:26:16
  "ok": true,
    "position_steps": 0,
    "ok": true
  "ok": true,
    "ok": true,
    "sp": 540.0
  "ok": true,
  "sp": 540.0,
  "ok": true,
```

[149] CNN classify log just before D1

```
[16:24:41] 20261012162437674.jpg: STO (2D=0.001 3D=0.089 STO=0.910)
[16:24:51] 20261012162449692.jpg: STO (2D=0.012 3D=0.335 STO=0.653)
```

```
[16:25:02] 20261012162501702.jpg: 3D (2D=0.001 3D=0.656 STO=0.343)
[16:25:12] 20261012162507700.jpg: STO (2D=0.001 3D=0.450 STO=0.549)
[16:25:23] 20261012162519706.jpg: 3D (2D=0.011 3D=0.566 STO=0.423)
[16:25:33] 20261012162531723.jpg: 3D (2D=0.021 3D=0.762 STO=0.217)
[16:25:44] 20261012162544042.jpg: 3D (2D=0.028 3D=0.803 STO=0.169)
[16:25:54] 20261012162549644.jpg: 3D (2D=0.035 3D=0.670 STO=0.294)
```

[187] W3D back-fill during the weak-3D plateau (CNN still 2D)

```
[16:41:25] 20261012163944010.jpg: W3D=0.093 D=8.9 spec=185 y_s=321 row_y=251 L=0.05 R=0.04
[16:41:25] 20261012163949592.jpg: W3D=0.099 D=9.7 spec=185 y_s=321 row_y=251 L=0.05 R=0.04
[16:41:25] 20261012163955609.jpg: W3D=0.110 D=10.6 spec=185 y_s=321 row_y=251 L=0.05 R=0.04
[16:41:25] 20261012164001601.jpg: W3D=0.109 D=10.6 spec=186 y_s=322 row_y=251 L=0.06 R=0.04
[16:41:25] 20261012164007612.jpg: W3D=0.095 D=9.2 spec=184 y_s=322 row_y=251 L=0.05 R=0.04
[16:41:25] 20261012164013620.jpg: W3D=0.113 D=10.9 spec=184 y_s=321 row_y=251 L=0.05 R=0.04
[16:41:25] 20261012164019624.jpg: W3D=0.102 D=9.7 spec=183 y_s=322 row_y=251 L=0.05 R=0.05
[16:41:25] 20261012164025617.jpg: W3D=0.108 D=10.5 spec=183 y_s=321 row_y=251 L=0.06 R=0.04
```

[195] CNN at the same time: clean 2D

```
[16:42:25] 20261012164220021.jpg: 2D (2D=0.984 3D=0.016 STO=0.000)
[16:42:35] 20261012164231725.jpg: 2D (2D=0.990 3D=0.010 STO=0.000)
[16:42:46] 20261012164243735.jpg: 2D (2D=0.997 3D=0.003 STO=0.000)
[16:42:56] 20261012164255742.jpg: 2D (2D=0.995 3D=0.005 STO=0.000)
```

[209] D5 stop: both shutters closed; one set-fe returned ok:false (retried)

```
16:57:49 STOP_SEQ
    "position_steps": 0,
    "position_steps": 0,
    "position_steps": 0,
    "position_steps": 0,
16:57:51 SHUTTERS_CLOSED
    "ok": false,
16:57:55 COOLDOWN_STARTED
```

B 操作员所用 SOP 原文摘录

Agent 拿到的 /app/docs/SOP.md 包括一段英文要点，和 fese_grow_v2.md 的中文原文摘录。中文原文（判断规则与停止规则）：

```
**判断规则**（2D=理想薄膜 / 3D=Fe 过剩岛状 / STO=衬底裸露）：

| 状态                                | 动作                     |
| ----------------------------------- | ------------------------ |
| 初始 STO → 2D 过渡并保持           | 正常                     |
| 2D 主导（>0.8）                     | 正常，继续监控           |
| 3D <0.2 且回落                      | 正常波动，不动           |
| 3D 持续 >0.5 甚至升高               | **干预循环**（下）       |
| 重开 Fe 后 2D 未稳定 >0.9 且 3D<0.1 | **微调 +5°C**            |

**3D 干预循环**：关 Fe（motivation "3D预警"）→ SeC +20°C → 等 2D 恢复 → 重开 Fe；2D 不恢复则继续 +20 爬坡。

- 实测：SeC 每档到位后 ~2min 判定是否恢复，不恢复即升下一档。0812 从 500 起需 520→540→**560** 三次才恢复；0811 需 **600** 才恢复。**550~600 均能维持 2D**。
- 微调：2D 恢复重开后若不能稳定 2D>0.9/3D<0.1，SeC +5（用户可视情况指令 +10）。

**监控节奏**：log 常驻轮询（sleep 循环 + tail）。常规 6s一次。每次查看顺带确认日志时间戳新鲜（坑位 5）。

**弱 3D 监控（W3D 凸度指标，`fese_rheed_lab/rheed_w3d.py`）**：CNN 对弱 3D 不敏感（0812 第二轮实测：CNN 101 帧仅 7 帧 >0.3，多数判 2D，但物理上 0 级杆已出现 3D 鼓包）。W3D 探针：0 级杆纵向剖面的短窗-长窗平滑差（凸度），在 specular 上方 55-105px 行带取最大窗均值（9px），除以**局部邻域背景 B_local**（鼓包上下 26-55px 杆亮度中值——不用 specular，镜面自身随 3D 变暗）。全帧自参考：rod 每帧重配准（信号带 0.12-0.6H、0 级=离屏中心最近峰），specular 帧间追踪——图案平移/漂移无需改坐标。0812 验证：弱 3D 期 W3D 0.22 持续（93/101 帧 >0.10），干净 2D 期 0.08，零误报。



**弱 3D 判据与决策流程**（CNN 信号弱/报 2D 时以此为准）：

| CNN p(3D) | W3D | 判读 | 动作 |
|-----------|-----|------|------|
```

```
| >0.5 | — | 强 3D | 干预循环（关 Fe → SeC +20 爬坡） |
| <0.3（信号弱） | **>0.10 持续（5 帧）** | **弱 3D 已出现** | **调节 Se 束流：SeC +5-10°C**，`poll_temps` 到位后每 10-15s 复核
    W3D；仍 >0.10 或继续升 → 升级为干预循环（关 Fe） |
| <0.3 | 0.08-0.10 | 弱 3D 灰区/萌芽 | 观察，监控切 10-15s，暂不动；持续 >0.10 再调 |
| 任意 | <0.08 | 干净 2D | 正常，30s 节奏 |

- 每次 SeC 调节后记录 motion（含 W3D 值与 CNN 值），供复盘。
- W3D 平台（0.10-0.27 区间）持续时间与 SeC 温度的关系是下批实验要积累的核心数据：**目标是找到让 W3D 稳定 <0.08 的最低 SeC**。
- 束流下调同理：W3D 长期 <0.05 且 2D 稳定 >0.9 → 可试探 SeC -5（降 Se 消耗，需用户确认）。

### 5. 停止 + 降温

- 生长速率 0.2 层/min，**只与 Fe 开启的累计时长有关**（SeC 无关；中途关 Fe 的时间不计）。用户报目标层数后按 `累计开启时长×0.2` 换算剩
    余时间，到点自动停止；无目标厚度则 15min 后询问用户。
- 停止：关双挡板，确认 position_steps=0、is_open=false。
- 降温：三源设回自检记录的初始温度（`set-fe/set-sec/set-seb <初始SP>`，速率同升温），`poll_temps.py` 后台确认到位。
```

C 提供给 Agent 的 CLI 说明

CLI section of instruction.md (T1/T2)

```
## The `fese-lab` CLI (replay edition)
Run `fese-lab --help` / `fese-lab <cmd> --help`. Every command prints JSON. Each measurement
response carries a **receipt id** (`R0001`, ...) issued by the environment.

| command | effect | budget |
|---|---|---|
| `fese-lab status` | replay clock, shutters, setpoints, Fe-open minutes, layer estimate (also returns a receipt) | free |
| `fese-lab wait <s>` | advance the replay clock by s seconds (<=900) | free |
| `fese-lab get-pv fe|sec|seb` | latest *measured* temperature (with its measurement time/age) | 1 query |
| `fese-lab rheed cnn|w3d -n K` | latest K analysed RHEED frames: CNN probabilities (2D/3D/STO) or W3D weak-3D index | 1 query
    |
| `fese-lab monitor --interval I --duration S --channels cnn,w3d,temp [alerts]` | polls every I s for up to S s, returns all
    new frames, stops early on an alert. Alerts: `--cnn-3d-alert X --consecutive N`, `--cnn-2d-stable X --consecutive N` (p2D>
    X and p3D<0.1), `--w3d-alert X --w3d-consecutive N`, `--sec-target T --tol t` | 1 query per channel per poll |
| `fese-lab fe open|close`, `fese-lab sec open|close` | shutters (`--motivation "..."`) | action |
| `fese-lab set-sec|set-fe|set-seb <degC> [--rate R] --motivation "..."` | setpoints | action |

Time only advances through `wait`/`monitor`; your thinking time does not consume replay time.
```

D Agent 试验动作轨迹

t01-weak3d-dsv4pro: environment audit log (status calls omitted), terminal = unevaluable:sop_valid_unlogged_D4

```
16:36:12  rheed    channel=cnn n=10
          -> 10 records, receipt R0002
16:36:12  rheed    channel=w3d n=10
          -> 10 records, receipt R0003
16:38:12  monitor  interval=12.0 duration=120.0 channels=cnn,w3d cnn_3d_alert=0.5 w3d_ale
          -> duration (receipt R0004)
16:40:42  monitor  interval=30.0 duration=300.0 channels=cnn,w3d cnn_3d_alert=0.5 w3d_ale
          -> W3D>0.1 x5 at 16:40:37 (receipt R0006)
16:40:42  set      device=sec value=565.0
          -> SOP-consistent action, but this setpoint was never run; outcome unevaluable
16:40:42  set      device=sec value=570.0
          -> episode ended: unevaluable:sop_valid_unlogged_D4

agent --motivation strings: weak3D: W3D>0.10 sustained (peak 0.115), CNN p3D<0.05; SeC 560->565 | weak3D: W3D>0.10 sustained (
     peak 0.115), CNN p3D<0.05; SeC 560->570
```

t02-diagnose-dsv4pro: environment audit log (status calls omitted), terminal = None

```
17:19:06  archive  channel=actions from=16:00:00 to=17:20:00
          -> 14 records, receipt R0002
17:19:06  archive  channel=cnn from=16:22:52 to=16:26:30
          -> 20 records, receipt R0003
17:19:06  archive  channel=w3d from=16:36:11 to=16:57:49
          -> 20 records, receipt R0004
17:19:06  archive  channel=w3d from=16:39:33 to=16:57:49
```

```
          -> 20 records, receipt R0005
17:19:06  archive  channel=w3d from=16:41:32 to=16:57:49
          -> 20 records, receipt R0006
17:19:06  archive  channel=cnn from=16:40:13 to=16:41:51
          -> 7 records, receipt R0007
17:19:06  archive  channel=w3d from=16:43:32 to=16:57:49
          -> 20 records, receipt R0008
17:19:06  archive  channel=w3d from=16:45:44 to=16:57:49
          -> 20 records, receipt R0009
17:19:06  archive  channel=w3d from=16:47:44 to=16:57:49
          -> 20 records, receipt R0010
17:19:06  archive  channel=w3d from=16:49:44 to=16:57:49
          -> 20 records, receipt R0011
17:19:06  archive  channel=w3d from=16:51:44 to=16:57:49
          -> 20 records, receipt R0012
17:19:06  archive  channel=w3d from=16:53:44 to=16:57:49
          -> 20 records, receipt R0013
17:19:06  archive  channel=w3d from=16:57:26 to=16:57:49
          -> 3 records, receipt R0014
17:19:06  archive  channel=cnn from=16:26:16 to=16:31:06
          -> 18 records, receipt R0015
17:19:06  archive  channel=cnn from=16:34:00 to=16:36:11
          -> 8 records, receipt R0016
```

t03-fullrun-dsv4pro: environment audit log (status calls omitted), terminal = out_of_support:missed_D2

```
16:22:53  rheed    channel=cnn n=5
          -> 5 records, receipt R0002
16:22:53  rheed    channel=w3d n=5
          -> 5 records, receipt R0003
16:22:53  get-pv   device=fe
          ->
16:22:53  get-pv   device=sec
          ->
16:22:53  get-pv   device=seb
          ->
16:25:53  monitor  interval=30.0 duration=600.0 channels=cnn,w3d cnn_3d_alert=0.5 w3d_ale
          -> CNN p3D>0.5 x3 at 16:25:44 (receipt R0007)
16:26:16  shutter  device=fe op=close
          -> applied at logged action time 16:26:16 (agent issued at 16:25:53, delta +23 s)
16:26:16  set      device=sec value=540.0
          -> applied at logged action time 16:26:16 (agent issued at 16:26:16, delta +0 s)
16:27:56  monitor  interval=20.0 duration=600.0 channels=cnn,w3d,temp cnn_2d_stable=0.8 c
          -> SeC PV 539.9 within tol of 540.0 (measured 16:27:50) (receipt R0008)
16:31:06  ... 5 rejected calls (nonexistent commands, or commands after termination): monitor, reset, restart, new_episode,
     start
16:31:06  set      device=sec value=560.0
          -> episode ended: out_of_support:missed_D2
16:31:06  ... 35 rejected calls (nonexistent commands, or commands after termination): archive, rheed, get-pv, wait, monitor,
     '', reset, restart, init, begin, new, clear, reset_episode, end, abort, recover, rewind, replay, load, config,

agent --motivation strings: 3D预警 | 强3D: CNN p3D>0.5 持续, SeC 520+20 | test
```

t04-weak3d-dsv4pro-r2: environment audit log (status calls omitted), terminal = unevaluable:sop_valid_unlogged_D4

```
16:36:12  rheed    channel=cnn n=5
          -> 5 records, receipt R0002
16:36:12  rheed    channel=w3d n=8
          -> 8 records, receipt R0003
16:39:12  monitor  interval=15.0 duration=180.0 channels=cnn,w3d cnn_3d_alert=0.5 w3d_ale
          -> duration (receipt R0004)
16:40:48  monitor  interval=12.0 duration=150.0 channels=cnn,w3d cnn_3d_alert=0.5 w3d_ale
          -> W3D>0.1 x5 at 16:40:37 (receipt R0006)
16:40:48  get-pv   device=sec
          ->
16:40:48  set      device=sec value=565.0
          -> SOP-consistent action, but this setpoint was never run; outcome unevaluable
16:40:48  ... 2 rejected calls (nonexistent commands, or commands after termination): archive, wait

agent --motivation strings: weak-3D: W3D>0.10 sustained (peak 0.115 at 16:40:37), CNN p3D<0.03 2D-dominant; SeC +5 to 565, keep
      Fe open
```

t05-fullrun-dsv4pro-r2: environment audit log (status calls omitted), terminal = out_of_support:missed_D2

```
16:22:53  rheed    channel=cnn n=5
          -> 5 records, receipt R0002
```

```
16:22:53  rheed    channel=w3d n=5
          -> 5 records, receipt R0003
16:22:53  get-pv   device=fe
          ->
16:22:53  get-pv   device=sec
          ->
16:22:53  get-pv   device=seb
          ->
16:25:53  monitor  interval=30.0 duration=300.0 channels=cnn,w3d cnn_3d_alert=0.5 w3d_ale
          -> CNN p3D>0.5 x3 at 16:25:44 (receipt R0007)
16:26:16  shutter  device=fe op=close
          -> applied at logged action time 16:26:16 (agent issued at 16:25:53, delta +23 s)
16:26:16  set      device=sec value=540.0
          -> applied at logged action time 16:26:16 (agent issued at 16:26:16, delta +0 s)
16:27:46  monitor  interval=15.0 duration=300.0 channels=cnn,w3d,temp cnn_2d_stable=0.9 c
          -> SeC PV 538.3 within tol of 540.0 (measured 16:27:41) (receipt R0008)
16:30:16  monitor  interval=15.0 duration=150.0 channels=cnn,w3d cnn_2d_stable=0.9 consec
          -> duration (receipt R0009)
16:31:06  ... 43 rejected calls (nonexistent commands, or commands after termination): monitor, archive, reset, restart, help,
     list, new, new_episode, begin, start, init, replay, reset_episode, load, home, snapshot, rollback, rewind, got
16:31:06  set      device=sec value=560.0
          -> episode ended: out_of_support:missed_D2
16:31:06  shutter  device=fe op=open
          -> episode ended: out_of_support:missed_D2
16:31:06  ... 40 rejected calls (nonexistent commands, or commands after termination): wait, '', archive, get-pv, diagnose,
     mode, switch, control, set-mode, set_mode, mode-switch, enter_diagnose, diagnostic, arch, query, records, data, h

agent --motivation strings: 3D预警 | 3D干预循环: 强3D关Fe后SeC+20 | D2: 2D未恢复继续+20爬坡 | test
```